

Assignment #2

Brain Networks



Ομάδα: Κυριάκος Κίχης, Γιώργος Σιαλή

(d) Δημιουργία λίστας ακμών του μη κατευθυνόμενου δικτύου

Για το συγκεκριμένο ερώτημα χρησιμοποιήθηκε το αρχείο *connections_princeton.csv*, το οποίο περιέχει όλες τις κατευθυνόμενες συνάψεις μεταξύ νευρώνων στον εγκέφαλο της *Drosophila*. Κάθε εγγραφή περιγράφει μια σύνδεση από έναν νευρώνα *pre_root_id* προς έναν νευρώνα *post_root_id*.

Επειδή το ζητούμενο δίκτυο πρέπει να είναι **μη κατευθυνόμενο (undirected)**, δύο νευρώνες θεωρήθηκαν συνδεδεμένοι **μόνο όταν υπήρχε αμοιβαία σύνδεση**: δηλαδή ταυτόχρονα εγγραφή $i \rightarrow j$ και εγγραφή $j \rightarrow i$. Η επιλογή αυτή εξασφαλίζει ότι στο παραγόμενο γράφημα περιλαμβάνονται μόνο αμφίδρομες λειτουργικές συνδέσεις, όπως ζητείται από την εκφώνηση.

Για την παραγωγή της λίστας ακμών δημιουργήθηκε το αρχείο **edges.txt**, στο οποίο κάθε γραμμή έχει τη μορφή:

```
id_1    id_2
```

χωρίς καμία επανάληψη ακμής. Μετά τον έλεγχο αμοιβαιότητας σε όλα τα ζεύγη συνδέσεων, προέκυψαν **310.090** αμφίδρομες συνδέσεις, οι οποίες αποτελούν την τελική λίστα ακμών του δικτύου.

Η διαδικασία υλοποιήθηκε μέσω του script **create_edge_list.py**, το οποίο:

1. φορτώνει το dataset των συνδέσεων,
2. εντοπίζει όλα τα ζεύγη $i \rightarrow j$ και $j \rightarrow i$,
3. κρατά μόνο τις αμφίδρομες (undirected) συνδέσεις,
4. αποθηκεύει το τελικό αρχείο *edges.txt*.

```
Φόρτωση connections_princeton.csv ...  
Στήλες αρχείου: ['pre_root_id', 'post_root_id', 'neuropil', 'syn_count', 'nt_type']  
Σύνολο γραμμών: 5342446  
Αμφίδρομες συνδέσεις που βρέθηκαν: 310,090  
✓ Το αρχείο edges.txt δημιουργήθηκε επιτυχώς!
```

(e) Συνολικός αριθμός κόμβων, μέσος βαθμός και μέσος συντελεστής συσσωμάτωσης

Για το υποερώτημα αυτό αναλύθηκε το μη κατευθυνόμενο δίκτυο που προέκυψε από το προηγούμενο βήμα (edges.txt). Το γράφημα κατασκευάστηκε με χρήση της βιβλιοθήκης *NetworkX*, από την οποία εξήχθησαν οι βασικές δομικές ιδιότητες του νευρωνικού δικτύου.

Ο συνολικός αριθμός κόμβων που συμμετέχουν στο δίκτυο είναι **102.757**, ενώ ο αριθμός των αμφίδρομων συνδέσεων είναι **310.090**. Από αυτά τα στοιχεία ο μέσος βαθμός προκύπτει ως:

$$\langle k \rangle = \frac{2E}{N} \approx 6.04$$

τιμή που βρίσκεται εντός των αναμενόμενων ορίων για μεγάλα βιολογικά δίκτυα, τα οποία τείνουν να είναι αραιά αλλά όχι εξαιρετικά σπάνια.

Στη συνέχεια υπολογίστηκε ο μέσος συντελεστής συσσωμάτωσης (average clustering coefficient). Σύμφωνα με την εκφώνηση, οι κόμβοι βαθμού 1 εξαιρέθηκαν από τον υπολογισμό, καθώς το clustering τους είναι μηδενικό και θα μετέτρεπε τεχνητά τη μέση τιμή προς τα κάτω. Με την απαραίτητη αυτή διόρθωση, ο μέσος συντελεστής συσσωμάτωσης (average clustering) βρέθηκε:

$$C = 0.2260$$

ενώ για σύγκριση, η τιμή που περιλαμβάνει και κόμβους βαθμού 1 είναι **0.1680**. Η τιμή $C \approx 0.23$ υποδηλώνει μέτρια τοπική ομαδοποίηση, χαρακτηριστική για βιολογικά δίκτυα όπου νευρώνες που συνδέονται συχνά μοιράζονται κοινούς γείτονες.

Τα αποτελέσματα επιβεβαιώνουν ότι το δίκτυο διαθέτει σημαντικό αλλά όχι υπερβολικά υψηλό επίπεδο τοπικής δομής, κάτι αναμενόμενο για μεγάλης κλίμακας συνδεσμολογίες όπως το connectome της *Drosophila*.


Όλα αυτά υλοποιήθηκαν μέσω του script **analyze_network.py**.

στα πραγματικά βιολογικά δίκτυα: παρότι παρουσιάζουν heavy tails, δεν ακολουθούν τέλεια power-law κατανομές.

Συνοπτικά, η κατανομή βαθμού του connectome της *Drosophila* εμφανίζει σαφή heavy-tailed συμπεριφορά και τάση προς power-law, με εκθέτη γύρω στο $\gamma \approx 2.41$, αν και η στατιστική υποστήριξη δεν είναι ισχυρή σε όλο το εύρος των βαθμών.

Το **degree_fit_results.json** και το γράφημα **degree_distribution_loglog.png** συμπεριλαμβάνονται πιο κάτω, ενώ η διαδικασία υλοποιήθηκε με το **degree_distribution.py**.

```
{ } degree_fit_results.json > ...  
1 {  
2   "nodes": 102757,  
3   "k_max": 4448,  
4   "powerlaw_gamma": 2.4145576346884843,  
5   "powerlaw_xmin": 17,  
6   "compare_R": -11.578895133387112,  
7   "compare_p": 0.015164578449094655  
8 }
```



(g) Μέση απόσταση, διάμετρος και χαρακτηρισμός small-world

Για τον υπολογισμό των αποστάσεων χρησιμοποιήθηκε το μη κατευθυνόμενο γράφημα του ερωτήματος (d). Επειδή το γράφημα δεν είναι πλήρως συνδεδεμένο, οι υπολογισμοί έγιναν στο **μεγαλύτερο συνδεδεμένο component**, το οποίο περιλαμβάνει **98.583 κόμβους**. Η μέση απόσταση (average shortest path length) εκτιμήθηκε με δειγματοληπτική προσέγγιση (sampling) πάνω στο συγκεκριμένο component, λόγω του μεγάλου μεγέθους του δικτύου.

Η μέση απόσταση βρέθηκε:

$$\ell \approx 6.91,$$

ενώ η διάμετρος (μέγιστη συντομότερη απόσταση μεταξύ δύο κόμβων, σε προσέγγιση) εκτιμήθηκε ως:

$$D \approx 29.$$

Για να κρίνουμε αν το δίκτυο είναι small-world, συγκρίναμε τη μέση απόσταση με τη θεωρητική τάξη μεγέθους $\log N$, όπου N ο αριθμός κόμβων του component. Για $N \approx 10^5$ παίρνουμε:

$$\log(N) \approx 11.50, \quad \log(\log(N)) \approx 2.44.$$

Η τιμή $\ell \approx 6.92$ είναι συγκρίσιμη με το $\log(N)$ και σαφώς πολύ μεγαλύτερη από το $\log(\log(N))$, γεγονός που υποδεικνύει ότι το δίκτυο παρουσιάζει **χαρακτηριστικές αποστάσεις τύπου small-world**, αλλά όχι ultra-small-world. Σε συνδυασμό με τον σχετικά υψηλό συντελεστή συσσωμάτωσης (average clustering) που υπολογίστηκε στο (ε), μπορούμε να συμπεράνουμε ότι το reciprocal connectome της *Drosophila* εμφανίζει τυπική **small-world τοπολογία**: μικρές μέσες αποστάσεις και ταυτόχρονα έντονη τοπική ομαδοποίηση.

Χρησιμοποιήθηκε η **graph_distance_diameter.py**.

```
Φόρτωση γραφήματος...
Το γράφημα δεν είναι πλήρως συνδεδεμένο. Υπολογισμοί στο μεγαλύτερο component (98583 nodes).
Υπολογισμός average shortest path length (με sampling)...
Υπολογισμός διαμέτρου (προσέγγιση)...

- ΑΠΟΤΕΛΕΣΜΑΤΑ (g) -
Average distance (ℓ): 6.909
Diameter (approx): 29
log(N) ≈ 11.50, log(log(N)) ≈ 2.44
Κατηγοριοποίηση: Small-world
```

(h) Assortativity: Έλεγχος συσχέτισης βαθμού κόμβων

Για να προσδιοριστεί κατά πόσο το δίκτυο είναι assortative, disassortative ή uncorrelated, υπολογίστηκε η συνάρτηση $k_{nn}(k)$, δηλαδή ο μέσος βαθμός των γειτόνων των κόμβων με βαθμό k . Το γράφημα $k_{nn}(k)$ απεικονίστηκε σε κλίμακα log–log.

Η καμπύλη παρουσιάζει μια καθαρά φθίνουσα τάση: όσο αυξάνεται ο βαθμός k ενός κόμβου, τόσο μικραίνει ο μέσος βαθμός των γειτόνων του. Αυτό δηλώνει ότι οι κόμβοι υψηλού βαθμού τείνουν να συνδέονται με κόμβους μικρού βαθμού — χαρακτηριστικό γνώρισμα **disassortative mixing**.

Για ποσοτική επιβεβαίωση, υπολογίστηκε ο degree assortativity coefficient του δικτύου:

$$r \approx -0.0545,$$


τιμή αρνητική, η οποία υποδηλώνει αδύναμη αλλά σαφή τάση **disassortative συσχέτισης**. Αυτό είναι σύμφωνο με την τυπική συμπεριφορά βιολογικών και τεχνολογικών δικτύων, στα οποία οι “hubs” συνδέονται κυρίως με κόμβους χαμηλότερης βαθμολόγησης.

Συμπερασματικά, το reciprocal connectome της *Drosophila* εμφανίζει **disassortative τοπολογία**, τόσο από την οπτική του $k_{nn}(k)$ plot όσο και από τον assortativity coefficient.

Ακολουθούν τα αποτελέσματα της `knn_plot.py` και το γράφημα `knn_loglog.png`:

```
Φόρτωση γραφήματος...
Υπολογισμός μέσου βαθμού γειτόνων (k_nn)...

– ΑΠΟΤΕΛΕΣΜΑΤΑ (h) –
Degree assortativity coefficient (r): -0.0545
Κατηγοριοποίηση: Disassortative
✅ Δημιουργήθηκε το γράφημα knn_loglog.png
```



(i) Πιθανότητα σύνδεσης ως συνάρτηση της απόστασης – Geometric scaling

Χρησιμοποιώντας το αρχείο συντεταγμένων (*coordinates.csv*), υπολογίστηκε η πιθανότητα $P(d)$ δύο νευρώνων να είναι συνδεδεμένοι στο δίκτυο του (d), ως συνάρτηση της φυσικής τους απόστασης d στον εγκέφαλο. Για πρακτικούς λόγους επιλέχθηκε τυχαίο υποσύνολο **20.000** νευρώνων με έγκυρες τρισδιάστατες συντεταγμένες. Για όλους τους ζεύγους νευρώνων στο δείγμα υπολογίστηκε η ευκλείδεια απόσταση και δημιουργήθηκε ιστόγραμμα όλων των αποστάσεων $n(d)$. Στη συνέχεια εντοπίστηκαν οι συνδεδεμένοι ζεύγοι μέσα στο ίδιο δείγμα και υπολογίστηκε αντίστοιχο ιστόγραμμα $n_c(d)$ μόνο για αυτά τα ζεύγη.

Η ζητούμενη πιθανότητα ορίστηκε ως

$$P(d) = \frac{n_c(d)}{n(d)},$$

όπου οι αποστάσεις ομαδοποιήθηκαν σε λογαριθμικά bins από την ελάχιστη μέχρι τη μέγιστη τιμή. Το τελικό γράφημα $P(d)-d$ σε log-log κλίμακα δείχνει ότι η πιθανότητα σύνδεσης φθίνει μονοτονικά όσο αυξάνεται η απόσταση. Για αποστάσεις της τάξης 10^3 nm η πιθανότητα είναι περίπου 10^{-1} , ενώ για αποστάσεις κοντά στα 10^5-10^6 nm η πιθανότητα πέφτει κοντά στο 10^{-6} . Στο ενδιάμεσο εύρος 10^3-10^5 nm τα σημεία σχηματίζουν σχεδόν ευθεία γραμμή σε log-log κλίμακα, κάτι που αποτελεί ένδειξη **power-law** συμπεριφοράς $P(d) \propto d^{-\alpha}$.

Συγκρίνοντας ποιοτικά το σχήμα μας με τα Fig. 1(g-i) του άρθρου “*Geometric Scaling Law in Real Neuronal Networks*”, παρατηρούμε πολύ παρόμοιο σχήμα: η πιθανότητα σύνδεσης μειώνεται σχεδόν γραμμικά σε log-log κλίμακα στο ίδιο περίπου εύρος αποστάσεων και με παρόμοια κλίση. Επομένως, τα αποτελέσματά μας **συμφωνούν ποιοτικά** με το paper και υποστηρίζουν την ύπαρξη **γεωμετρικού νόμου κλιμάκωσης** στο connectome της *Drosophila*: νευρώνες που βρίσκονται κοντά στο χώρο έχουν πολύ μεγαλύτερη πιθανότητα να συνδέονται, και η πιθανότητα αυτή μειώνεται περίπου με νόμο δύναμης όσο μεγαλώνει η απόσταση.

Ακολουθούν τα αποτελέσματα της `distance_connectivity_plot.py` και το γράφημα `distance_connectivity_loglog.png`:

```
Φόρτωση δεδομένων...  
Νευρώνες με έγκυρες συντεταγμένες: 139,255  
Δείγμα κόμβων για ανάλυση: 20000  
Αριθμός συνδέσεων στο δείγμα: 5,638  
✓ Δημιουργήθηκε το γράφημα distance_connectivity_loglog.png
```

